


Exploração de Dados

CONCEITOS

População, Amostra e Viés

População = todos os elementos estudados

Amostra = parte representativa



Por que amostrar?

Custo, tempo, acessibilidade, privacidade

Amostragem Aleatória


- *Cada indivíduo tem a mesma chance de ser escolhido*
- *Reduz viés*

Exemplos de viés real

- Pesquisa de opinião feita só pela internet (exclui quem não tem acesso)
- Estimar renda apenas com amostra de bairros ricos
- Aumentar o tamanho não corrige viés


SOLUÇÃO: AMOSTRAGEM ALEATÓRIA

Aleatória Simples



Cada membro tem a mesma chance de ser escolhido.

Estratificada



Vital para garantir representação de minorias.


Tamanho da Amostra e Erro-Padrão

Exemplo numérico:

- $s = 12$
- $n = 100 \rightarrow SE = 12/10 = 1,2$
- $n = 400 \rightarrow SE = 12/20 = 0,6$
- *4x mais dados $\rightarrow$ erro cai pela metade*

Quanto maior a amostra $\rightarrow$ menor a variação


$$SE = \frac{s}{\sqrt{n}}$$



Interpretação prática:

- Resultados ficam mais estáveis
- Mas qualidade da amostra importa mais que tamanho

Distribuição Amostral e Variação



Distribuição de Dados Individuais

Valores individuais são ruidosos e não normais.

Média de 5

A forma começa a se condensar.

Média de 20

Distribuição da Estatística (Média).

Se repetirmos o processo de amostragem, a média muda um pouco:

Exemplo (média real 50):

- Amostra 1 $\rightarrow$ 48,7
- Amostra 2 $\rightarrow$ 51,2
- Amostra 3 $\rightarrow$ 49,5

Essas médias formam a distribuição amostral da média

Isso permite:

- medir erro
- construir intervalos de confiança
- fazer testes estatísticos

Teorema do Limite Central (TLC)

A média das amostras tende a ser Normal quando o tamanho n é suficiente.



Exemplo prático:

População: salários (extremamente assimétricos)

- $n=5 \rightarrow$ distribuição das médias ainda torta
- $n=30 \rightarrow$ começa a se aproximar da Normal
- $n=100 \rightarrow$ curva quase perfeitamente Normal

Consequência:

Podemos usar Normal/t para IC e testes, mesmo com dados assimétricos, desde que a amostra seja razoavelmente grande.



Intervalos de Confiança (IC)

IC de 95% mostra uma faixa provável onde está o valor real da média:

Clássico (Normal/t):


$$\bar{x} \pm 1.96 * SE$$

Exemplo:

- Média da amostra = 4.2 (escala 0–5)
- $s = 0.8$
- $n = 200 \rightarrow SE = 0.8 / \sqrt{200} = 0.056$
- $IC = 4.2 \pm 1.96 \cdot (0.056) \rightarrow [4.09, 4.31]$

Interpretação correta:

Se repetíssemos muitas vezes, 95% desses intervalos conteriam a média verdadeira.



Bootstrap

Quando:

- Amostras pequenas
- Dados assimétricos
- Estatística não Normal (ex.: mediana)

Exemplo:

Amostra: [10, 12, 8, 15, 9]

Reamostragens (exemplos reais):

- [10, 10, 9, 15, 12] → média 11,2
- [12, 12, 8, 9, 15] → média 11,2
- [8, 9, 9, 12, 10] → média 9,6

Percentis 2.5% e 97.5% das médias → IC bootstrap


Como funciona:

- Pegue a amostra original
- Reamostragem com reposição muitas vezes
- Calcule média (ou outra estatística) em cada reamostra
- Use os percentis para formar o IC

✓ Funciona mesmo sem suposições de normalidade

✓ Muito usado em Machine Learning e modelos complexos

Bootstrap




Distribuições Estatísticas Importantes

Distribuição	Quando usar	Exemplo real
Normal	Erros e médias (TLC)	Média de 100 salários $\approx$ normal
t de Student	Amostra pequena + variância desconhecida	Média de 12 pacientes
Poisson	Contagem de eventos por tempo/área	100 clientes $\rightarrow$ quantos compram?
Binomial	Sucesso/fracasso em n tentativas	Ligações por minuto no suporte
Exponencial	Tempo até próximo evento	Tempo entre chegadas de clientes
Weibull	Tempo até falha	Confiabilidade de peças/maquinário

Moral do Capítulo

- Amostragem aleatória >>> tamanho.
- TLC torna médias previsíveis.
- Erro-padrão diminui com a fórmula apresentada.
- ICs medem incerteza da estimativa.
- Bootstrap resolve casos difíceis (poucos dados, assimetria).
- Distribuições diferentes → problemas diferentes.
- Conhecer as distribuições evita erros de modelagem.



Referência do Capítulo (Parte de Monografia)

BRUCE, Peter; BRUCE, Andrew. Distribuições de Dados e Amostras. In: BRUCE, Peter; BRUCE, Andrew. Estatística prática para cientistas de dados: 50 conceitos essenciais. Rio de Janeiro: Alta Books, 2019. cap. 2.

Referência do Livro Completo (Monografia no todo)

BRUCE, Peter; BRUCE, Andrew. Estatística prática para cientistas de dados: 50 conceitos essenciais. Rio de Janeiro: Alta Books, 2019.

UNIVERSIDADE FEDERAL DO PIAUÍ

CCN - CIÊNCIA DA COMPUTAÇÃO

PAVIC - Pesquisas Aplicadas a Visão e Inteligência Computacional

PROFº RICARDO LIRA E PROFº KELLY LIMA

BIANCA DA SILVA MAGALHÃES PINHEIRO

TERESINA, 2025