



Distribuições de Dados e Amostras

Estatística Prática para Cientistas de Dados - Cap. 2



Amostragem Aleatória e Viés de Amostra

- Amostra $\times$ População;
- Amostragem aleatória simples e estratificada;
- Viés de amostragem;

- **Ex.:**

Em uma pesquisa eleitoral, entrevistar apenas moradores de um bairro rico gera um viés — a amostra não reflete a diversidade da população.

- Tamanho vs. Qualidade;
- Média Amostral ($\bar{x}$) vs. Média Populacional (μ).



Viés de Seleção


- **Definição:** Prática de escolher dados de forma seletiva (consciente ou não), levando a conclusões enganosas.
- **Bisbilhotagem de Dados (Data Snooping):** Pesquisa extensiva nos dados até que algo interessante (mas provavelmente aleatório) apareça.
- **Efeito de Busca Vasta:** Viés resultante da modelagem repetitiva dos mesmos dados.
- **Regressão à Média:** Fenômeno em que observações extremas (ex: sorte excepcional) tendem a ser seguidas por observações mais próximas da média.

Distribuição de Amostragem

- Distribuição de dados $\times$ distribuição amostral;
- Teorema do Limite Central (TLC);
- Erro-padrão e regra da raiz de n .

- Ex.:

Se coletarmos médias de notas de turmas diferentes, mesmo com distribuições diferentes por aluno, as médias das turmas formarão uma curva de sino.





Intervalos de Confiança (IC)

- **Propósito:** Apresentar uma estimativa como uma amplitude (*range*) para quantificar a incerteza, em vez de um único número.
- **Nível de Confiança:** A porcentagem (ex: 90% ou 95%) de intervalos que conteriam o verdadeiro valor da população se o processo fosse repetido.
- **Interpretação (*Bootstrap*):** O intervalo que abrange os X% centrais da distribuição amostral bootstrap.
- **Relações:** Mais dados ou menor confiança resultam em um intervalo mais estreito; menos dados ou mais confiança resultam em um intervalo mais largo.



Distribuição Normal

Distribuição	Quando usar	Exemplo real
Normal	Erros e médias (TLC)	Média de 100 salários $\approx$ normal
t de Student	Amostra pequena + variância desconhecida	Média de 12 pacientes
Poisson	Contagem de eventos por tempo/área	100 clientes $\rightarrow$ quantos compram?
Binomial	Sucesso/fracasso em n tentativas	Ligações por minuto no suporte
Exponencial	Tempo até próximo evento	Tempo entre chegadas de clientes
Weibull	Tempo até falha	Confiabilidade de peças/maquinário