



REGRESSÃO & PREVISÃO

DA TEORIA À PRÁTICA.



RESUMO

A regressão é apresentada como uma ferramenta fundamental na estatística e na ciência de dados, servindo a dois propósitos principais: explicação (entender a relação entre variáveis) e previsão (predizer valores futuros)



$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

Predição da
Variável Dependente

Intercepto ou
constante do modelo

Incremento
na variável 01
(Ex: H)

Incremento
na variável 02
(Ex: H)

variável 01
(Ex: H)

variável 02
(Ex: H)

EXPLICAÇÃO X PREVISÃO



Históricamente usada pra entender relacionamentos globais. O foco está no coeficiente b_1 (o impacto de X em Y)

EX.: O gasto com anúncios aumenta as vendas do produto?



Na era do BigData, o foco muda para estimar resultados individuais. O foco está em $\hat{Y}$ (o valor previsto)

EX.: Qual é o valor específico desta casa?

Regressão Linear Simples

Este é o bloco de construção básico. Ela modela a relação entre duas variáveis: uma que queremos prever (Y) e outra que usamos para fazer a previsão (X)

- ▶ A Equação: A relação é desenhada como uma linha reta: $Y = b_0 + b_1X$.
- ▶ Intercepto (b_0): É onde a linha cruza o eixo Y. É o valor previsto quando X é zero
- ▶ Declive ou Coeficiente (b_1): Indica quanto Y muda para cada unidade que X aumenta
- ▶ Valor Ajustado ($Y^{\wedge}$): É o valor que o modelo prevê para um determinado dado
- ▶ Resíduo (e): É o erro da previsão. É a diferença entre o valor real que observamos e o valor ajustado pelo modelo ($Y - Y^{\wedge}$)
- ▶ Mínimos Quadrados (OLS): Como o computador escolhe a "melhor" linha? Ele busca a linha que passa o mais perto possível de todos os pontos ao mesmo tempo


Exposição ao Algodão vs. Capacidade Pulmonar

O texto usa dados de trabalhadores expostos à poeira de algodão.

- 01 O problema: Queremos saber como os anos de exposição (Exposure) afetam a capacidade pulmonar (PEFR)
- 02 O Modelo: $PEFR = 424.58 - 4.18 \times \text{Exposure}$
- 03 **Interpretação:**
 - Um trabalhador com 0 anos de exposição tem um PEFR esperado de 424.58 (intercepto).
 - Para cada ano extra de exposição, a capacidade pulmonar cai em média 4.18 unidades (declive negativo)

Regressão Linear Simples

PEFR vs. Exposição



A Pergunta: A variável X está associada à variável Y?


O Modelo: $Y = b_0 + b_1X$

Resposta (Y): Variável Dependente ou Alvo (ex: Capacidade Pulmonar).


Independente (X): Preditor ou Feature (ex: Anos de Exposição).

Intercepto (b_0): Valor de Y quando X=0.

Declive (b_1): Quanto Y muda para cada unidade de X.



Mínimos Quadrados (OLS)



Objetivo: Minimizar a soma dos erros ao quadrado (RSS).

$$\begin{aligned} RSS &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \\ &= \sum_{i=1}^n (Y_i - \hat{b}_0 - \hat{b}_1 X_i)^2 \end{aligned}$$

Valores Ajustados ($\hat{Y}_i$): A estimativa feita pela linha de regressão.

Resíduos (e_i): A diferença entre o valor real e o valor ajustado (o comprimento das linhas tracejadas).

Regressão Linear Múltipla

Na vida real, raramente uma única variável explica tudo. A regressão múltipla expande a equação para incluir vários preditores ($X_1, X_2, \dots, X_p$)

Exemplo Prático: Imóveis em King County

$$Y = b_0 + b_1X_1 + b_2X_2 + \dots + b_pX_p + e$$

(Intercept)	SqFtTotLiving	SqFtLot	Bathrooms
-5.219e+05	2.288e+02	-6.051e-02	-1.944e+04
Bedrooms	BldgGrade		
-4.778e+04	1.061e+05		

- ▶ Variáveis usadas: Metros quadrados construídos (SqFtTotLiving), tamanho do lote, banheiros, quartos e nota da construção (BldgGrade)
- ▶ Interpretação: Se o coeficiente de SqFtTotLiving é 229, significa que adicionar 1 metro quadrado à casa aumenta o valor estimado em \$229, assumindo que todas as outras variáveis permaneçam iguais

Avaliando o Modelo (Como sabemos se é bom?)

RMSE (Raiz do Erro Quadrático Médio)

$$\text{RMSE} = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n}}$$

- Mede a precisão geral do modelo na mesma unidade de Y (dólares).
- Quanto menor, melhor.

R² (Coeficiente de Determinação)

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

- A proporção da variabilidade dos dados explicada pelo modelo.
- Escala de 0 a 1. Quanto mais próximo de 1, melhor o ajuste.

Estatística t e Valor p: Ajudam a decidir se uma variável é estatisticamente significativa ou se seu efeito pode ser fruto do acaso. Cientistas de dados usam a estatística t como um guia: valores altos indicam que a variável é importante para o modelo

Seleção de Modelo e Validação

Não devemos apenas jogar todas as variáveis possíveis no modelo.

Validação Cruzada (Cross-Validation)

Métricas clássicas (como R^2) medem o erro nos dados usados para criar o modelo ("na amostra"). Isso pode enganar.

- O Método: Devemos separar parte dos dados (amostra de retenção) para testar o modelo. A validação cruzada k-fold divide os dados em k partes, treina em algumas e testa em outras, repetindo o processo para garantir robustez

Seleção de Variáveis:

Adicionar variáveis sempre diminui o erro no treino, mas pode complicar o modelo desnecessariamente (overfitting).

AIC (Critério de Informação de Akaike):

É uma métrica que penaliza modelos complexos. O objetivo é encontrar o modelo com o menor AIC (equilíbrio entre precisão e simplicidade)

Regressão Passo a Passo (Stepwise):

Um algoritmo que adiciona ou remove variáveis automaticamente para encontrar o melhor AIC. No exemplo das casas, o algoritmo removeu variáveis como "ano de renovação" porque não ajudavam o modelo o suficiente

Regressão Ponderada:

Usada quando alguns dados são mais importantes ou precisos que outros. No exemplo das casas, vendas mais recentes receberam peso maior que as antigas

Variáveis Fatoriais (Categóricas)

A regressão só entende números. Como lidar com texto, como "Tipo de Imóvel" (Casa, Apartamento, etc.)?

Conversão para Variáveis Fictícias (Dummies)

- ▶ Transformamos categorias em colunas binárias (0 ou 1).
- ▶ **Codificação de Referência:** Se temos 3 tipos de imóveis, criamos 2 colunas. A categoria que falta vira a "referência" (o padrão).
- ▶ **Exemplo:** No texto, "Multiplex" é a referência. Se o imóvel for "Single Family", o coeficiente mostrou uma queda de valor de \$85.000 em relação ao Multiplex

O Problema de Muitos Níveis

- ▶ Variáveis como Código Postal (ZipCode) podem ter centenas de categorias, o que cria centenas de colunas.
- ▶ **Solução:** Agrupar categorias. O texto sugere agrupar os códigos postais em 5 grupos baseados no preço médio (ou resíduo médio) daquela região (ZipGroup 1 a 5)

Interpretando a Equação (Armadilhas)

A interpretação dos coeficientes pode ser enganosa se não tivermos cuidado.

Preditores Correlacionados

Quando duas variáveis "andam juntas" (como tamanho da casa e número de quartos), o modelo se confunde ao atribuir crédito.

O Paradoxo dos Quartos:

No modelo inicial, o coeficiente para Bedrooms (quartos) era negativo. Isso significa que ter mais quartos diminui o valor da casa? Não.

A Explicação:

Como o modelo já tinha o tamanho total da casa, adicionar quartos (mantendo o tamanho fixo) significa quartos menores. Quartos minúsculos desvalorizam a casa. Ao remover o tamanho da casa da equação, o coeficiente de quartos torna-se positivo

Variáveis de Confundimento

É quando uma variável importante é esquecida, distorcendo os resultados.

● Exemplo:

Inicialmente, variáveis como tamanho do lote e banheiros tinham coeficientes estranhos (negativos ou baixos). O problema? Faltava a Localização. Ao adicionar a variável ZipGroup (localização), os coeficientes se corrigiram, pois a localização é um fator determinante de preço

Interações

Às vezes, o efeito de uma variável depende de outra.


● Exemplo(tamanhoXlocalização):

Adicionar 1 metro quadrado em um bairro pobre valoriza pouco a casa. Adicionar o mesmo metro em um bairro rico valoriza muito. Isso é uma interação. O modelo mostrou que o metro quadrado no bairro mais caro vale quase 3 vezes mais que no mais barato

Diagnósticos de Regressão

Após criar o modelo, precisamos verificar se ele é confiável e se existem dados estranhos.

Outliers (Valores Extremos):



- **Cenário:**
: Prever o valor de um lote vazio.
- **Resultado:**
O modelo prevê um preço negativo pois o intercepto é negativo.
- **Lição:**
O modelo só é válido dentro da faixa de dados observada. Ele não possui “senso comum”

Diagnósticos de Regressão

Após criar o modelo, precisamos verificar se ele é confiável e se existem dados estranhos.

Valores Influentes:

São dados que, se removidos, mudam drasticamente a linha de regressão (mudam os coeficientes).

- **Diagnóstico:** Usa-se o "Gráfico de Influência" ou "Gráfico Bolha" combinando resíduos e a Distância de Cook. No exemplo das casas, remover alguns pontos influentes mudou o coeficiente de banheiros de positivo para negativo, mostrando a fragilidade de modelos mal ajustados

Heteroscedasticidade:

Ocorre quando o erro do modelo não é constante.

- **Exemplo:** O gráfico de resíduos mostrou que o erro de previsão aumenta conforme o preço da casa aumenta (o modelo erra mais em casas caras). Isso sugere que o modelo está incompleto para faixas de preços altos

Regressão Não Linear

Gráficos de Resíduos Parciais

Ajudam a visualizar a relação isolada entre uma variável e a resposta.

- Exemplo: O gráfico para SqFtTotLiving (tamanho da casa) vs. Preço mostrou uma curva. Casas muito pequenas ou muito grandes não seguiam a linha reta perfeitamente.

Soluções para Não Linearidade

1. Polinomial
2. Splines
3. GAM (Modelos Aditivos Generalizados)

Soluções para Não Linearidade

Polinomial:

Adicionar termos ao quadrado (X^2). O texto ajustou um polinômio quadrático ao tamanho da casa, criando uma curva que se ajustou melhor aos dados.

Splines:

Uma técnica mais avançada que ajusta curvas suaves conectadas por pontos chamados nós. É como desenhar uma curva usando uma régua flexível. O spline se ajustou ainda melhor aos dados de habitação do que o polinômio.

GAM (Modelos Aditivos Generalizados):

Uma técnica que descobre automaticamente a melhor curva (onde colocar os nós) para os dados. No exemplo, o GAM capturou a relação complexa entre tamanho e preço de forma automática.

