

REGRESSÃO E PREVISÃO

Cap. 4 - Estatística Prática para cientista
de dados

INTRODUÇÃO

Um dos principais objetivos da estatística é verificar se existe associação entre variáveis (como $X_1, \dots, X_p$) e uma variável Y , entender a natureza dessa relação e avaliar se ela pode ser usada para prever Y . A forte ligação entre estatística e ciência de dados, especialmente na previsão de uma variável alvo (Y) a partir de variáveis preditoras (X) e na detecção de anomalias por meio de diagnósticos de regressão.


REGRESSÃO LINEAR SIMPLES


- Modela o relacionamento entre duas variáveis;
- Diferente da Correlação (mede a força de uma associação entre duas variáveis);
- Equação de Regressão:

$$Y = b_0 + b_1X$$


Onde:

- Y = Variável Resposta
- b_1 = Coeficiente de Inclinação
- b_0 = Intercepto (constante quando $X = 0$)
- X = Variável Preditora






NOTAÇÃO CHAPÉU



Usada para diferir as estimativas (incertezas) dos valores conhecidos. Então o símbolo $\hat{b}$ (“b-chapéu”) é uma estimativa do parâmetro desconhecido b . Por que os estatísticos diferenciam entre a estimativa e o valor real? A estimativa tem incerteza, enquanto o valor real é fixado.

VALORES AJUSTADOS E RESÍDUOS



- No geral, os dados não ficam exatamente em uma linha reta. Logo, a equação de regressão deveria incluir um termo explícito de erro, ficando: $Y = b_0 + b_1X + e_i$
 - No entanto, como não sabemos o valor do erro (aleatório), usamos uma estimativa, que é fornecida pela fórmula de valores ajustados (ou previstos): $\hat{Y}_i = \hat{b}_0 + \hat{b}_1X_i$
 - As notações $\hat{b}_0$ e $\hat{b}_1$ indicam que os coeficientes são os valores estimados
-
- Calculamos os resíduos $\hat{e}_i$ subtraindo os valores previstos dos dados originais: $\hat{e}_i = Y_i - \hat{Y}_i$

MÍNIMOS QUADRADOS

- Tem como objetivo encontrar a reta que minimiza a soma dos quadrados dos resíduos:

Residual Sum of Squares 

$$RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$
$$= \sum_{i=1}^n (Y_i - \hat{b}_0 - \hat{b}_1 X_i)^2$$

- Ao realizar a minimização, obtém-se as seguintes fórmulas:

- Coeficiente angular: é a inclinação da reta, ou seja, quanto Y varia, em média, quando X aumenta uma unidade.
- Intercepto: representa o ponto de partida da reta no eixo vertical (X = 0).

Coeficiente angular 

$$\hat{b}_1 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(X_i - \bar{X})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$


Intercepto 

$$\hat{b}_0 = \bar{Y} - \hat{b}_1 \bar{X}$$


PREVISÃO VS. EXPLICAÇÃO

Historicamente, um dos primeiros usos da regressão era desvendar um suposto relacionamento linear entre as variáveis preditoras e uma variável resultante. O objetivo tem sido entender um relacionamento e explicá-lo usando os dados para os quais a regressão foi ajustada.

No entanto, sozinha, a equação de regressão não prova a direção de causa. As conclusões sobre a causa devem vir de um contexto maior de entendimento sobre o relacionamento. É o nosso conhecimento sobre o processo, e não a equação de regressão, que nos leva à conclusões sobre os dados.



REGRESSÃO LINEAR MÚLTIPLA



- Extensão para múltiplas variáveis preditoras:

$$Y = b_0 + b_1X_1 + \dots + b_pX_p$$

- Exemplo prático: Previsão de preços imobiliários.
- Complexidade *versus* interpretabilidade.

AValiação DO DESEMPENHO DO MODELO

- RMSE (Raiz Quadrada do Erro Quadrático Médio): mede a magnitude média dos erros:

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$

- R-Quadrado (R^2): Proporção da variância explicada pelo modelo:


$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Erro-padrão residual (RSE): forma do RMSE ajustada para graus de liberdade:

$$RSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n - p - 1)}}$$

SELEÇÃO DE MODELOS E VALIDAÇÃO CRUZADA

- O perigo do sobreajuste (*overfitting*).
- Validação Cruzada (K-fold): Testar o modelo em dados não vistos.
- Regressão Passo a Passo (Stepwise): Adição/remoção automática de variáveis.




VARIÁVEIS FATORIAIS (CATEGÓRICAS)

- Conversão de categorias em números.
- Codificação de variáveis fictícias (*Dummy variables*).
- Tratamento de fatores com muitos níveis (ex: códigos postais).

DIAGNÓSTICOS DE REGRESSÃO

Outliers e Influência e Heterocedasticidade

OUTLIERS E INFLUÊNCIA



- Outliers: Valores extremos nos resíduos.
- Distância de Cook (ou D de Cook): métrica estatística usada para identificar a influência de cada observação individual em um modelo de regressão linear
- Valores Influentes: Pontos que alteram drasticamente a equação (Distância de Cook).
- Diferença entre *outlier* e ponto de alta alavancagem.


HETEROCEDASTICIDADE

- Heterocedasticidade: Quando a variância do erro não é constante.
- **Análise de resíduos parciais para detectar não linearidade.**

Impacto na validade das inferências.



ALÉM DA LINEARIDADE (SPLINES E GAM)


- Regressão Polinomial: Adição de termos de potência (X^2)
 - Splines: Curvas suaves que conectam pontos (nós).
 - Modelos Aditivos Generalizados (GAM).
- 
- A decorative graphic consisting of several overlapping, curved, light blue and white shapes that sweep upwards from the bottom right corner of the slide, creating a modern, abstract background element.

RESUMO

Regressão é uma ferramenta fundamental para previsão e explicação.

O foco do cientista de dados está no poder preditivo e na validação.

A regressão linear é a base para métodos mais avançados.



OBRIGADO!