



Classificação – Capítulo 5

Sumário:

1.

Naive Bayes

2.

Análise
Discriminante

3.

Regressão
Logística

4.

Avalaiando Modelos
de Classificação

Naive Bayes

USA A PROBABILIDADE DE OBSERVAÇÃO DE VALORES PREDITORES, DADO UM RESULTADO, PARA ESTIMAR A PROBABILIDADE DE OBSERVAR O RESULTADO $Y = i$, DADO UM CONJUNTO DE VALORES PREDITORES.

TERMOS-CHAVE

PROBABILIDADE CONDICIONAL

A probabilidade de observar algum evento (digamos $X = i$) dado algum outro evento (digamos $Y = i$), escrito como $P(X_i | Y_i)$.

PROBABILIDADE POSTERIOR

A probabilidade de um resultado após a informação preditora ter sido incorporada (ao contrário da probabilidade de resultados anterior, não considerando a informação preditora)

Por que a Classificação Bayesiana Exata é Impraticável

Quando o número de variáveis preditoras excede a quantidade, muitos dos registros a serem classificados ficarão sem correspondências exatas.

A Solução Naive

Não restringimos mais o cálculo da probabilidade àqueles registros que se correspondem com o registro a ser classificado. Em vez disso, usamos todo o conjunto de dados.

^ explicado nos slides do Yuri

Variáveis Preditoras Numéricas

A partir da definição, vemos que o classificador Bayesiano funciona apenas com preditoras categóricas (por exemplo, com classificação de spam, em que a presença ou ausência de palavras, frases, caracteres e afins é o centro da tarefa preditiva).

- Discretizar e converter as preditoras numéricas em preditoras categóricas e aplicar o algoritmo da seção anterior.
- Usar um modelo de probabilidade — por exemplo, a distribuição normal para estimar a probabilidade condicional $P(X_j | Y = i)$.

Análise Discriminante

TERMOS-CHAVE

COVARIÂNCIA

Uma medida da extensão em que uma variável varia em conjunto com outra (ou seja, magnitude e direção semelhantes).

FUNÇÃO DISCRIMINANTE

A função que, quando aplicada às variáveis preditoras, maximiza a separação das classes.

PESOS DISCRIMINANTES

As pontuações que resultam da aplicação da função discriminante e são usadas para estimar as probabilidades de pertencer a uma ou outra classe.

A análise discriminante pode fornecer uma medida da importância preditora e é usada como um método computacionalmente eficiente para a seleção de características.

MATRIZ DE COVARIÂNCIA

A covariância mede o relacionamento entre duas variáveis x e z .

A correlação, no entanto, é restrita a estar entre -1 e 1 , enquanto a covariância está na mesma escala que as variáveis x e z . A matriz de covariância Σ para x e z é composta pelas variâncias individuais das variáveis, e, na diagonal (em que linha e coluna são a mesma variável) e as covariâncias entre os pares de variáveis fora da diagonal

DISCRIMINANTE LINEAR DE FISHER

Consideramos um problema de classificação binária, no qual o objetivo é prever um resultado Y a partir de duas variáveis numéricas contínuas (X e Z). A Análise Discriminante Linear (LDA) assume, teoricamente, normalidade das variáveis preditoras, mas apresenta bom desempenho mesmo quando essa suposição não é estritamente atendida. O método de Fisher procura separar os dados em dois grupos maximizando a variabilidade entre os grupos SS_{between} em relação à variabilidade dentro dos grupos SS_{within} .

A soma dos quadrados entre os grupos mede a distância entre as médias das classes, enquanto a soma dos quadrados dentro dos grupos representa a dispersão interna. Maximizar a primeira e minimizar a segunda aumenta a separação entre os grupos.

REGRESSÃO LOGÍSTICA

A regressão logística é um modelo de classificação binária que estima a probabilidade de ocorrência de um evento. É um método popular devido à sua grande velocidade computacional e seu resultado de um modelo que se presta à rápida pontuação de novos dados

TERMOS-CHAVE

LOGITO

A função que mapeia a probabilidade de pertencimento a uma classe com amplitude de $\pm \infty$ (em vez de 0 a 1).

CHANCES

A proporção entre “sucesso” (1) e “não sucesso” (0).

CHANCES DE LOG

A resposta no modelo transformado (agora linear), que é mapeada até uma probabilidade.

FUNÇÃO DE RESPOSTA LOGÍSTICA E LOGITO

Mapeamos a probabilidade (que fica em uma escala 0–1) para uma escala mais expansiva para modelagem linear.

O primeiro passo consiste em tratar a variável resposta como a probabilidade p de ocorrência da classe 1, e não como um rótulo binário. Contudo, um modelo linear direto não garante que $p \in [0,1]$. Para contornar essa limitação, utiliza-se a razão de chances, definida como $p/(1-p)$. A aplicação do logaritmo nessa razão — a função logito — transforma o intervalo $(0,1)$ em $(-\infty, +\infty)$, permitindo o uso de um modelo linear. A probabilidade estimada pode então ser convertida em rótulo de classe por meio de uma regra de decisão baseada em um limiar pré-definido.

REGRESSÃO LOGÍSTICA E O GLM

A regressão logística modela a probabilidade p de ocorrência de um evento binário.

Modela-se o logito $\log(p/(1-p))$, que mapeia $p \in (0,1)$ para $(-\infty, +\infty)$. O logito é expresso como uma combinação linear das variáveis explicativas. A probabilidade é recuperada pela função logística, garantindo valores entre 0 e 1. A classificação resulta da aplicação de um limiar sobre p .

A regressão logística é um caso particular dos Modelos Lineares Generalizados (GLM). Em um GLM, especificam-se: (i) a distribuição da resposta (binomial, no caso logístico), (ii) o preditor linear, e (iii) a função de ligação (logito). Os parâmetros são estimados por máxima verossimilhança.

MODELOS LINEARES GENERALIZADOS (GLM)

Definidos por dois componentes:

- Família de distribuição da variável resposta (ex.: binomial, Poisson, gama).
- Função de ligação que relaciona a média da resposta aos preditores lineares.

REGRESSÃO LOGÍSTICA

- Caso particular de GLM.
- Distribuição: binomial.
- Função de ligação: logito.
- Modela a probabilidade de ocorrência de um evento (classe 1).
- A probabilidade estimada pode ser convertida em rótulo por regra de corte.

OUTROS GLMS

- Poisson: dados de contagem.
- Binomial negativa / Gama: tempo até evento.
- Exigem maior cuidado na especificação e interpretação.

Regressão Linear e Logística: Semelhanças e Diferenças

Semelhanças

- Ambas assumem forma paramétrica linear nos preditores.
- Processo de exploração, seleção e ajuste de modelo é similar.
- Técnicas do modelo linear (ex.: splines) também se aplicam à regressão logística.

Diferenças Fundamentais

- Método de ajuste:
 - Linear: mínimos quadrados.
 - Logística: máxima verossimilhança (MLE).
- Natureza dos resíduos e sua análise diferem entre os modelos.

Regressão Linear e Logística: Semelhanças e Diferenças

Ajuste do Modelo

- Regressão Linear:
 - Ajuste por mínimos quadrados.
 - Avaliação: RMSE e R^2 .
- Regressão Logística:
 - Sem solução fechada.
 - Ajuste por MLE.
 - Modela o log das chances do evento (classe 1).
 - Avaliação baseada em desviância (menor é melhor).

Estimação de Máxima Verossimilhança (MLE)

- Objetivo: encontrar os parâmetros que maximizam a probabilidade dos dados observados.
- Ajuste via otimização iterativa (quase-Newton / pontuação de Fisher).
- Implementação é tratada pelo software estatístico.

Avaliando Modelos de Classificação

TERMOS-CHAVE

PRECISÃO

O percentual (ou proporção) de casos classificados corretamente.

SENSIBILIDADE

O percentual (ou proporção) de 1s corretamente classificados.

ESPECIFICIDADE

O percentual (ou proporção) de 0s corretamente classificados.

EXATIDÃO

O percentual (proporção) de 1s previstos que são realmente 1s.

CURVA ROC

Um gráfico de sensibilidade versus especificidade.

LIFT

Uma medida de quão eficaz é o modelo em identificar (comparativamente raros) 1s em diferentes cortes de probabilidade.

MATRIZ DE CONFUSÃO

Uma exibição tabular (2×2, no caso binário) das contagens do registro por seu status de classificação previsto e real.

Matriz de Confusão

- Tabela que resume previsões corretas e incorretas em problemas de classificação.
- Linhas: valores reais. Colunas: valores previstos.
- Elementos da diagonal: acertos.
- Fora da diagonal: erros.

Caso Binário

- $Y = 1$: evento de interesse.
- $Y = 0$: evento negativo.
- Facilmente calculada manualmente.

Métricas Derivadas

- A matriz de confusão é a base para métricas como:
 - Acurácia
 - Precisão
 - Revocação (sensibilidade)
 - Especificidade
- Taxa de falsos positivos é crítica quando a classe 1 é rara.

Interpretação Importante

- Quando 1s são raros, muitos positivos previstos podem ser falsos.
- Um resultado positivo pode ser mais provavelmente um 0.
- Situação comum em triagens médicas e detecção de fraude.

Classe Rara e Limitação da Acurácia

- Em dados desbalanceados, a classe menos frequente é geralmente a mais relevante.
- Erros nessa classe (falsos negativos) tendem a ter maior custo.
- Acurácia pode ser enganosa: prever sempre a classe majoritária pode gerar alto desempenho aparente, mas pouco valor prático.
- Modelos úteis priorizam a identificação da classe rara, mesmo com menor acurácia global.

Limitação da Acurácia

Alta acurácia pode ser enganosa.

Problema da Classe Rara

- Classes desbalanceadas: uma classe é muito menos frequente.
- A classe rara costuma ser a de maior interesse.
- Erros em 1s (falsos negativos) geralmente têm custo maior.

Impacto na Avaliação

- Um modelo pode ter alta acurácia prevendo sempre a classe majoritária.
- Exemplo: prever sempre 0 pode gerar 99,9% de acerto, mas nenhum valor prático.

Precisão, Revocação e Especificidade

- Métricas usadas para avaliar modelos de classificação, especialmente em dados desbalanceados.
- Comuns em estatística, bioestatística e aprendizado de máquina.

Precisão (Precision)

- Mede a confiabilidade das previsões positivas.
- Proporção de positivos previstos que são corretos.
- Alta precisão $\Rightarrow$ poucos falsos positivos.

Revocação (Recall / Sensibilidade)

- Mede a capacidade de identificar corretamente os positivos reais.
- Proporção de positivos reais corretamente previstos.
- Alta revocação $\Rightarrow$ poucos falsos negativos.

Especificidade (Specificity)

- Mede a capacidade de identificar corretamente os negativos reais.
- Proporção de negativos reais corretamente previstos.
- Alta especificidade $\Rightarrow$ poucos falsos positivos.

Observação

- Precisão, revocação e especificidade capturam aspectos diferentes do desempenho.
- A escolha da métrica depende do custo relativo dos erros.

Curva ROC

- Representa a troca entre revocação (sensibilidade) e especificidade.
- Capturar mais 1s geralmente aumenta a classificação incorreta de 0s como 1s.
- O classificador ideal maximiza a identificação dos 1s sem aumentar falsos positivos.

Construção da Curva ROC

1. Ordenar os registros pela probabilidade prevista de classe 1 (do maior para o menor).
2. Variar o ponto de corte.
3. Calcular revocação e especificidade cumulativas.

Definição

- Curva ROC (Receiver Operating Characteristic):
 - Eixo y: Revocação (sensibilidade).
 - Eixo x: Especificidade (ou $1 -$ especificidade, por convenção).
- A forma da curva é equivalente, independentemente da convenção do eixo x.

Interpretação

- Cada ponto da curva corresponde a um ponto de corte.
- Resume o desempenho do classificador para todos os limiares possíveis.

AUC (Área Sob a Curva ROC)

- A curva ROC é informativa, mas não fornece uma medida única de desempenho.
- A AUC resume a curva ROC em um único valor numérico.

Definição

- AUC = área total sob a curva ROC.
- Mede a capacidade do modelo de discriminar entre classes.

Observação Prática

- AUC pode ser calculada por integração numérica da curva ROC.
- Valores baixos (ex.: ~0,59) indicam classificador fraco.

Interpretação

- AUC = 1,0: classificador perfeito.
- AUC = 0,5: desempenho equivalente ao acaso (linha diagonal).
- Quanto maior a AUC, melhor o classificador.

Confusão sobre Taxa de Falso Positivo

- As taxas de falso positivo e falso negativo são frequentemente confundidas com especificidade e sensibilidade.
- Essa ambiguidade ocorre inclusive em softwares e publicações.

Duas Definições Comuns

- Taxa de falso positivo (estatística clássica):
 - Proporção de negativos reais classificados como positivos.
 - Equivale a $1 - \text{especificidade}$.
- Uso alternativo (contexto aplicado):
 - Proporção de positivos previstos que são, na verdade, negativos.
 - Comum em áreas como detecção de intrusão.

Lift (Ganho)

- A AUC melhora a avaliação além da acurácia, mas não resolve totalmente o problema da classe rara.
- Em cenários raros, o ponto de corte costuma ser menor que 0,5 para evitar classificar tudo como 0.
- Isso implica superidentificar 1s, aceitando mais falsos positivos.

Uso Prático

- Ajuda a definir pontos de corte operacionais.
- Útil quando há restrição de recursos (ex.: auditorias, campanhas, triagem).

Gráfico de Lift (ou Ganhos)

- Mostra o desempenho acumulado do modelo.
- Eixo x: proporção de registros avaliados.
- Eixo y: revocação (ganhos cumulativos).
- Lift = razão entre a curva de ganhos e a linha diagonal (aleatória).

Uplift (Observação)

- Às vezes usado como sinônimo de lift.
- Uso específico: comparação entre tratamentos (A/B).
- Mede a diferença de resposta prevista entre dois tratamentos para um mesmo indivíduo.

Estratégias para Dados Desequilibrados

TERMOS-CHAVE

UNDERSAMPLE

Usar menos registros da classe prevalente no modelo de classificação.

OVERSAMPLE

Usar mais registros da classe rara no modelo de classificação, bootstrapping, se necessário.

PONDERAÇÃO ACIMA OU PONDERAÇÃO ABAIXO

Aplicar mais (ou menos) peso à classe rara (ou prevalente) no modelo.

GERAÇÃO DE DADOS

Igual ao bootstrapping, exceto pelo fato de que cada novo registro bootstrapped é ligeiramente diferente de sua fonte.

SCORE Z

O resultante depois da padronização.

K

O número de vizinhos considerados no cálculo de vizinho mais próximo.

Undersampling

- Reduz a classe majoritária para equilibrar 0s e 1s.
- Parte do princípio de que a classe dominante tem muitos registros redundantes.
- Benefícios: melhor desempenho, dados menores e análise mais simples.

Prática

- Dezenas de milhares de exemplos da classe dominante costumam ser suficientes.
- Quanto mais separáveis as classes, menos dados são necessários.

Efeito

- Dados equilibrados evitam viés do modelo para a classe majoritária.
- Sem undersampling, o modelo tende a subestimar a classe rara.

Oversampling e Ponderação

- **Oversampling:** replica a classe rara (com reposição) para equilibrar os dados.
- Evita descartar informação quando o conjunto é pequeno.
- **Ponderação:** atribui pesos maiores à classe rara e menores à majoritária.
- Efeito equivalente a over/undersampling, sem alterar o tamanho do dataset.

Observação

- A ponderação atua diretamente na função perda, penalizando mais os erros na classe rara.
- É uma solução simples e amplamente suportada por algoritmos.

Geração de Dados (SMOTE)

- Cria novos registros sintéticos a partir da classe rara.
- Variação do oversampling: não replica, perturba os dados existentes.
- Objetivo: fornecer mais diversidade para aprender regras mais robustas.

SMOTE

- Gera exemplos sintéticos combinando um registro raro com seus vizinhos mais próximos.
- Usa médias ponderadas aleatórias entre observações similares.
- Número de registros gerados depende do nível de balanceamento desejado.

Observação

- Muito usado em dados desbalanceados.
- Amplamente disponível em pacotes estatísticos.

Classificação Baseada em Custos

- Acurácia e AUC não refletem impacto financeiro.
- Decisão deve considerar custos de erros (FP vs FN).

Ideia Central

- Atribuir custo à inadimplência (C) e retorno ao pagamento (R).
- Classificar com base no retorno esperado, não apenas na probabilidade.

Implicação Prática

- A probabilidade prevista é apenas intermediária.
- A decisão final deve maximizar lucro esperado.
- Casos com menor valor podem ser preteridos por outros mais lucrativos, mesmo com maior risco.



Resumo — Classificação

- **Classificação prevê a qual classe um registro pertence.**
- **Em problemas binários, a classe de interesse é definida como 1 e costuma ser rara.**
- **Modelos geralmente estimam uma probabilidade (nota de propensão) de pertencer à classe 1.**
- **Classes desbalanceadas exigem métricas além da acurácia.**
- **Avaliação adequada é crucial quando prever tudo como 0 gera alta precisão, mas pouco valor.**

Muito Obrigada!