

Classificação

Estatística Prática para Cientistas de Dados - Cap. 5

A large, dark blue, curved shape that starts from the bottom left and extends diagonally upwards towards the right, filling the lower half of the slide.

Introdução

- Classificação como forma mais importante de previsão;
 - Classificação binária;
 - Probabilidade de pertencimento a classe e corte deslizante;
 - Decisões baseadas em propensões.
-
- Corte maior = menos registros previstos como 1;
 - Corte menor = mais registros previstos como 1.

Naive Bayes

Termos-chave

Probabilidade *a Priori*

Probabilidade inicial atribuída a um evento ($P(A)$) antes que qualquer nova evidência ou informação relevante seja considerada.

Probabilidade Condicional

A probabilidade de observar algum evento ($P(A)$) dado algum outro evento ($P(B)$):

$$P(A/B) = \frac{P(A \cap B)}{P(B)}$$

Probabilidade *a Posteriori*

A probabilidade de um resultado após a informação preditora ter sido incorporada.

$$P(A|B) = \frac{(P(B|A) * P(A))}{P(B)}$$

Como se relacionam?

A principal diferença reside no fluxo de informação:

- Você começa com uma **probabilidade a priori** (sua crença inicial).
- Você coleta novos dados/evidências (usando a **probabilidade condicional** para modelar a relação entre os dados e sua crença).
- Você usa o Teorema de Bayes para atualizar sua crença inicial, resultando na **probabilidade posterior** (sua crença revisada e mais informada)

Naive Bayes

Classificação Bayesiana Exata

1. Encontre todos os outros registros com o mesmo perfil preditivo (ou seja, nos quais os valores preditores sejam os mesmos);
2. Determine a quais classes aqueles registros pertencem e qual classe é prevalente (ou seja, provável);
3. Atribua aquela classe ao novo registro.

Problema: Impraticável maioria dos problemas de classificação de dados

Solução Naive (Naive Bayes Ingênuo)

1. Para uma resposta binária $Y = i$ ($i = 0$ ou 1), estime as probabilidades condicionais individuais para cada preditor $P(X_j | Y = i)$;
2. Multiplique essas probabilidades uma pela outra, e então pela proporção de registros pertencentes a $Y = i$;
3. Repita os Passos 1 e 2 para todas as classes;
4. Estimar uma probabilidade para o resultado i assumindo o valor calculado no Passo 2 para classe i e dividindo-o pela soma de tais valores para todas as classes;
5. Atribua o registro à classe com a maior probabilidade para esse conjunto de valores preditores.

Variáveis Preditoras Numéricas

Para que seja possível aplicar o *Naive Bayes* em variáveis preditoras numéricas, deve-se adotar uma das abordagens a seguir:

1. Discretizar e converter as preditoras numéricas em preditoras categóricas e aplicar o algoritmo anteriormente explicado;
2. Usar um modelo de probabilidade — por exemplo, a distribuição normal — para estimar a probabilidade condicional $P(X_j | Y = i)$.

Análise

Discriminante

Termos-chave

Covariância

Uma medida da extensão em que uma variável varia em conjunto com outra (ou seja, magnitude e direção semelhantes).

Função discriminante

A função que, quando aplicada às variáveis preditoras, maximiza a separação das classes.

Pesos discriminantes

As pontuações que resultam da aplicação da função discriminante e são usadas para estimar as probabilidades de pertencer a uma ou outra classe.

Análise Discriminante

- Apresentado por Ronald Aylmer Fisher em 1936;
- Análise Discriminante Linear (LDA) – mais comumente usada;
- Um pouco diferente do proposto por Fisher, mas com a mesma mecânica;
- Menos usada por conta do advento de técnicas mais sofisticadas;
- Fornece medida da importância preditora;
- Usada como método eficiente na seleção de características.

Matriz de Covariância

- A Matriz de Covariância (Σ) é uma matriz que organiza as variâncias e covariâncias de um conjunto de variáveis;

$$\hat{\Sigma} = \begin{bmatrix} s_x^2 & s_{x,z} \\ s_{x,z} & s_z^2 \end{bmatrix}$$

- As variâncias individuais das variáveis (por exemplo, σ_x^2 e σ_z^2) estão localizadas na diagonal da matriz;
- As covariâncias entre pares de variáveis ($\sigma_{i,j}$) estão localizadas fora da diagonal;
- É uma matriz simétrica, o que significa que a covariância entre as variáveis i e j é igual à covariância entre j e i ($\sigma_{i,j} = \sigma_{j,i}$);
- A matriz de covariância está na mesma escala das variáveis x e z .

Discriminante Linear de Fisher

Objetivo: maximizar a separação entre as classes em um problema de classificação.

Ex.: Concentração de Ácido Málico.

Tipo de Uva (Classe)	Concentração de Ácido Málico (x_j)
A	1.1, 1.3, 1.2, 1.0
B	3.5, 3.8, 3.6, 3.9

1° Passo: Cálculo das médias

Média da Classe A ($\bar{x}_A$): $(1.1+1.3+1.2+1.0) / 4 = 1.15$

Média da Classe B ($\bar{x}_B$): $(3.5+3.8+3.6+3.9) / 4 = 3.7$

Média Global ($\bar{x}$): $(1.15+3.7) / 2 = 2.425$

Discriminante Linear de Fisher

2° Passo: Calcular a Dispersão "*Within*"
(Soma dos Quadrados Dentro das Classes)

Calculamos o quanto cada ponto varia em relação à sua própria média.

Dispersão em A: $(1.1 - 1.15)^2 + (1.3 - 1.15)^2 + (1.2 - 1.15)^2 + (1.0 - 1.15)^2 = 0.045$

Dispersão em B: $(3.5 - 3.7)^2 + (3.8 - 3.7)^2 + (3.6 - 3.7)^2 + (3.9 - 3.7)^2 = 0.1$

Total Within (S_{Within}): $0.045 + 0.1 = 0.145$

3° Passo: Calcular a Dispersão "*Between*"
(Soma dos Quadrados Entre Classes)

Calculamos o quanto as médias dos grupos variam em relação à média geral.

Dispersão em A: $n_A \times (\bar{x}_A - \bar{x})^2 = 4 \times (1.15 - 2.425)^2 = 4 \times (-1.275)^2 \approx 6.5025$

Dispersão em B: $n_B \times (\bar{x}_B - \bar{x})^2 = 4 \times (3.7 - 2.425)^2 = 4 \times (1.275)^2 \approx 6.5025$

Total Between (S_{Between}): $6.5025 + 6.5025 = 13.005$

Discriminante Linear de Fisher

4° Passo: Otimização (A Razão de Fisher)

A LDA procura a direção que maximiza a razão ($S_{\text{Between}}/S_{\text{Within}}$). Neste exemplo unidimensional, essa razão é:

$$13.005 / 0.145 \approx 89.69.$$

Como a LDA maximiza essa razão, ela garante que a separação entre as classes seja muito maior do que a variação (espalhamento) dentro de cada classe.

Regressão Logística

Se difere da regressão linear pois, em vez de prever um valor numérico, prevê a probabilidade de um evento ocorrer (entre 0 e 1) – um resultado binário.

Função Logito: Transforma a saída em uma curva em formato de "S", garantindo que as previsões fiquem dentro do intervalo de probabilidade válido.

$$\log (\text{Odds}(Y = 1)) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q.$$

Interpretação: Usa *Odds Ratio* (Razão de Chances) para explicar como o aumento em uma variável afeta a chance do resultado.

É o "padrão ouro" para modelagem de risco e classificação binária na indústria devido à sua interpretabilidade.

Modelos de Classificação

Avaliação de Modelos

Matriz de Confusão: Tabela 2x2 (no caso binário) que compara previsões vs. realidade.

- Verdadeiro Positivo;
- Falso Positivo;
- Verdadeiro Negativo;
- Falso Negativo.

Métricas Chave:

- Acurácia: Taxa geral de acertos (cuidado: enganosa em dados desbalanceados).
- Precisão (Precision): De tudo que o modelo chamou de "Positivo", quanto estava certo?
- Recall (Sensibilidade): De tudo que era realmente "Positivo", quanto o modelo encontrou?
- Especificidade: Capacidade de identificar corretamente os negativos.

Curva ROC e AUC

Curva ROC: Gráfico que mostra a troca (*trade-off*) entre a Sensibilidade (taxa de acerto nos positivos) e a Especificidade (taxa de falso alarme).




Figura 5-6. Curva ROC para os dados de empréstimo

AUC (Área Sob a Curva): Um número único para resumir a qualidade do modelo.

AUC = 1.0: Modelo perfeito.

AUC = 0.5: Modelo aleatório (chute).

Uso: Essencial para comparar qual modelo é melhor, independentemente do ponto de corte escolhido para a probabilidade.

Estratégias para Dados Desbalanceados

Problema: Quando uma classe é muito rara (ex.: Fraude é 0,1% dos dados), o modelo tende a ignorá-la e prever tudo como "Normal" para ter alta acurácia.

Soluções:

- **Undersampling (Subamostragem)**: Jogar fora dados da classe majoritária para equilibrar;
- **Oversampling (Sobreamostragem)**: Duplicar registros da classe minoritária;
- **SMOTE / Geração de Dados**: Criar dados sintéticos artificiais parecidos com a classe minoritária para "ensinar" melhor o modelo;
- **Pesos (Weights)**: Dar um peso maior ao erro na classe minoritária durante o treinamento.