

Estatística Prática para Cientistas de Dados
(Peter & Andrew Bruce)

CAPÍTULO 7 — APRENDIZADO NÃO SUPERVISIONADO

Regressão Linear



RESUMO

Este capítulo trata de técnicas de aprendizado não supervisionado, ou seja, métodos em que não existe uma variável-alvo (rótulo) previamente definida. O objetivo é descobrir padrões, estruturas internas, agrupamentos ou representações compactas dos dados.

Na computação e na ciência de dados, essas técnicas são amplamente usadas para análise exploratória, redução de dimensionalidade, segmentação de usuários, compressão de dados e pré-processamento para modelos supervisionados.

Fundamentos do Aprendizado Não Supervisionado

Extraindo significado de dados não rotulados



- **Definição:** Métodos estatísticos que extraem significado dos dados sem treinar um modelo em dados rotulados (sem variável resposta Y).
- **Objetivo:** Identificar grupos significativos, reduzir dimensionalidade e realizar análise exploratória avançada.
- **Usabilidade:** Essencial como etapa de pré-processamento para modelos preditivos, reduzindo a complexidade computacional e melhorando a precisão. Atua como um "filtro" para descobrir relacionamentos ocultos em grandes massas de dados antes da aplicação de modelos preditivos.

Análise de Componentes Principais (PCA)



- **Conceito:** Técnica para descobrir como variáveis numéricas covariam e reduzir a dimensão dos dados.
- **Como funciona:** Combina múltiplas variáveis originais em um conjunto menor de componentes principais (combinações lineares ponderadas) que explicam a maior parte da variância.
- **Exemplo Prático:** Análise de retornos de ações (ex: Chevron e ExxonMobil). O primeiro componente mostra a tendência geral do mercado, e o segundo mostra a diferença entre as ações.

Usabilidade na Computação:

- **Compressão de dados:** Armazenar informações essenciais com menos variáveis.
- **Visualização:** Projetar dados de 10+ dimensões em gráficos 2D ou 3D

Ideias-Chave - PCA (Redução de Dimensão)

- Problema: Datasets com excesso de variáveis contêm ruído e redundância que turvam o sinal verdadeiro.
- Solução: o PCA combina múltiplas variáveis numéricas em um conjunto menor de 'componentes principais' (combinações lineares ponderadas).
- Exemplo: ao analisar ações, o componente 1 captura a tendência geral do mercado, enquanto o componente 2 isola as diferenças específicas entre as empresas.



Agrupamento por K-Médias (K-Means)


- **Conceito:** Divisão dos dados em K grupos distintos e bem separados.
- **Como funciona:** Minimiza a soma das distâncias quadráticas de cada registro à média (centroide) do seu grupo.
- **Exemplo Prático:** Agrupamento de ativos financeiros ou segmentação de clientes em "personas" de compra.

Usabilidade na Computação:

- **Eficiência:** É um algoritmo rápido e escalável para Big Data.
- **Sistemas de Recomendação:** Agrupar usuários com gostos similares para sugerir produtos

Ideias-Chave - Agrupamento por K-Médias

- Restrição: o usuário deve definir K (nº de grupos) antes da execução. O algoritmo não adivinha quantos grupos existem.
- Métrica: Qualidade é medida pela compactação. Buscamos grupos com a menor soma de erros quadráticos possível. Grupos densos e bem separados indicam sucesso.
- Casos de uso: 1- Sistemas de recomendação: agrupar usuários com gostos similares.
2- Segmentação de clientes: criação rápida de personas.
3- Ativos financeiros: categorização baseada em comportamento de performance.



Agrupamento Hierárquico


- **Conceito:** Criação de uma hierarquia de grupos sem a necessidade de definir K antecipadamente.
- **Como funciona:** Começa com cada registro sendo um grupo e os funde iterativamente (algoritmo aglomerativo) com base na dissimilaridade (ligação única, média ou total).
- **O Dendrograma:** Visualização em árvore que mostra o histórico de fusão dos grupos.
- **Exemplo Prático:** Organização taxonômica de empresas ou espécies biológicas.

Usabilidade na Computação:

- **Deteccção de Anomalias:** Identificar registros que não se "encaixam" facilmente em nenhum grupo.
- **Análise de Cluster Flexível:** Permite ao analista escolher o nível de granularidade após o processamento

Ideias-Chave - Agrupamento Hierárquico

- Leitura do mapa: a altura das linhas verticais representa a distância entre os grupos. Quanto mais alta a fusão, mais diferentes são os grupos.
- Corte: uma linha horizontal define o número de clusters. Cortar a árvore em diferentes alturas resulta em diferentes quantidades de grupos.
- Aplicações: taxonomia biológica, hierarquias corporativas e detecção de anomalias (registros que demora a se fundir).



Agrupamento Baseado em Modelos


- **Conceito:** Assume que os dados vêm de uma mistura de distribuições de probabilidade (ex: Normais Multivariadas).
- **Como funciona:** Usa critérios estatísticos (como o BIC) para selecionar automaticamente o melhor número de grupos e o formato das distribuições.
- **Exemplo Prático:** Identificar períodos de alta e baixa volatilidade no mercado de ações através de misturas de distribuições.

Usabilidade na Computação:

- **Classificação Probabilística:** Diferente do K-means, ele dá a probabilidade de um item pertencer a um grupo, não apenas uma resposta "sim ou não".

Ideias-Chave - Agrupamento Baseado em Modelos

- Fundamento Estatístico: Assume que os dados derivam de diferentes processos geradores com distribuições de probabilidade distintas (ex: Normais Multivariadas).
- Automação: ele pode selecionar automaticamente o número ideal de grupos e sua forma geométrica.
- Critério BIC: Utiliza o Critério de Informação Bayesiano para evitar modelos excessivamente complexos e garantir o melhor ajuste.



Problema: Variáveis como Salário (100.000) esmagam variáveis como Idade (40). O algoritmo vê apenas o salário.

Solução: Normalização (Escore Z). Subtrair a média e dividir pelo desvio padrão coloca todas as variáveis na mesma escala.

O Desafio do Escalonamento e Dados Mistos

- **Importância do Escalonamento:** Variáveis com escalas maiores (ex: Salário vs. Idade) dominam o algoritmo se não forem normalizadas (Escore Z).
- **Variáveis Categóricas:** O uso de Distância de Gower é essencial quando temos dados numéricos e textuais misturados, trazendo tudo para uma escala 0-1.

Usabilidade na Computação:

- **Pipeline de Dados:** Inclusão de passos de normalização automáticos em fluxos de Machine Learning.

Ideias-Chave - Escalonamento e Dados Mistos

- Necessidade de Transformação: Variáveis em escalas diferentes precisam ser normalizadas (padronizadas) para que uma não domine o impacto do algoritmo sobre as outras.
- Padronização (Escore Z): O método mais comum, subtraindo a média e dividindo pelo desvio-padrão.
- Distância de Gower: Técnica essencial para lidar com conjuntos de dados que misturam números e categorias, escalonando tudo para uma amplitude de 0-1



Conclusão e Resumo de Usabilidade

- **Ponto Chave:** O aprendizado não supervisionado é o alicerce da intuição sobre os dados.

Aplicações Finais:

- **Pré-processamento:** Reduzir ruído e redundância (PCA).
- **Estratégia de Negócio:** Segmentação de mercado (Clustering).
- **Bioinformática e Engenharia:** Identificar padrões complexos em sensores e sequenciamento genético.

Resumo de Usabilidade Geral

- Descoberta: O aprendizado não supervisionado revela a estrutura oculta dos dados, permitindo segmentar mercados ou identificar anomalias sem rótulos prévios.

Técnica


- PCA
- K-Means
- Hierárquico
- Model Based

Objetivo Principal

Reduzir variáveis
Particionar dados
Mostrar relações
Descobrir distribuições

Ponto Forte na Computação

Velocidade e visualização
Escalável para Big Data
Estrutura visual clara (dendrograma)
Rigor estatístico e automação



OBRIGADA!

Livro fonte: BRUCE, Peter; BRUCE, Andrew. Estatística prática para cientistas de dados: 50 conceitos essenciais. Tradução de Luciana Ferraz. Rio de Janeiro: Alta Books, 2019. 320 p.

Aluna: Bianca da Silva Magalhães Pinheiro