

Aprendizado não-supervisionado


Estatística Prática para Cientistas de Dados - Cap. 7

Introdução

Métodos estatísticos que extraem significado dos dados sem o uso de rótulos ou resultados conhecidos.

Diferença Fundamental: Enquanto o aprendizado supervisionado busca prever uma resposta a partir de preditores, o não-supervisionado não distingue entre variável responsiva e variáveis preditoras.

Extensão da EDA: Pode ser visto como uma extensão da análise exploratória de dados para lidar com grandes volumes de variáveis e registros.



Objetivos e aplicações

“Por que usar essas técnicas?”

Identificação de Grupos: Criar regras de agrupamento para dados significativos (ex: segmentação de usuários em um site).

Redução de Dimensão: Reduzir milhares de variáveis (como sensores industriais) para um conjunto gerenciável, facilitando modelos preditivos posteriores.

Problema de "Partida a Frio": Útil quando não há dados históricos rotulados, como no lançamento de uma nova campanha de marketing ou detecção de novos tipos de fraude.

Análise de Componentes Principais (PCA)

Técnica para descobrir como variáveis numéricas covariam.

Combina múltiplas variáveis originais em um conjunto menor de "componentes principais", que são combinações lineares ponderadas.

Termos-chave:


- Cargas (Loadings): Pesos que transformam as preditoras em componentes.
- Screeplot: Gráfico que mostra a variância e a importância relativa de cada componente.

Exemplo Prático

Componente 1: Reflete a correlação entre as empresas (tendência geral do setor de energia).

Componente 2: Mede quando os preços das ações das duas empresas divergem.

O primeiro componente segue o eixo longo da elipse de variabilidade, enquanto o segundo segue o eixo curto.



Cálculo do PCA

Obs.: Funciona apenas com variáveis numéricas.

Maximização da Variância: Encontra a combinação linear que maximiza a variância explicada (Z_1).

Ortogonalidade: O processo se repete para criar Z_2 , garantindo que Z_1 e Z_2 não sejam correlacionados.

Conversão: O processo continua até que existam tantos componentes quanto variáveis originais, permitindo depois a redução para os mais importantes.

Componentes

Interpretação e escolha

Análise de Cargas: As cargas revelam a estrutura dos dados (ex: se todas as ações têm o mesmo sinal, reflete o mercado global).

Critérios de Seleção:

- Regra *Ad Hoc*: Selecionar componentes que explicam a "maior parte" da variância (ex: através do 'cotovelo' no *Screeplot*).
 - Limite de Variância: Parar quando a variância cumulativa atingir um limite (ex: 80%).
 - Validação Cruzada: Método formal para escolher o número de componentes significativos.
-

Agrupamento por K-Médias

Técnica para dividir dados em K grupos (*clusters*) onde os registros em cada grupo são semelhantes.

Objetivo: Minimizar a soma das distâncias quadráticas de cada registro à média de seu grupo (SS dentro do grupo).


Importância da Normalização: Variáveis devem ser padronizadas (escore Z), caso contrário, variáveis com grandes escalas dominarão o agrupamento.

Agrupamento Hierárquico

Diferente do K-Médias, o agrupamento hierárquico não exige a definição prévia do número de grupos (K).

Dendrograma: Uma representação visual em forma de árvore que mostra a hierarquia dos grupos e como os registos se unem.

Vantagem: Permite visualizar a estrutura dos dados em diferentes níveis de granularidade, facilitando a interpretação.



Dandograma de ações

Agrupamento baseado em Modelos

Fundamento Estatístico: Assume que os dados provêm de uma mistura de diferentes distribuições de probabilidade (geralmente Normais Multivariadas).

Componentes do Modelo: Cada grupo é definido por uma média (μ) e uma matriz de covariância (Σ) própria.

Limitações: Exige pressupostos subjetivos sobre o modelo e tem um custo computacional elevado, sendo difícil de escalar para *Big Data*.

Escalonamento e variáveis dominantes

O uso de Escores Z (subtrair a média e dividir pelo desvio-padrão) é o padrão para garantir que todas as variáveis contribuam igualmente.

O Problema da Escala: Variáveis com grandes amplitudes (ex: ações com preços altos como Google ou Amazon) podem dominar a análise se não forem tratadas.

Soluções: Reescalonar os dados ou tratar as variáveis dominantes separadamente, dependendo do objetivo da análise.

Dados Mistos

Distância de Gower

Como agrupar quando temos números e categorias (variáveis binárias/fatores) ao mesmo tempo?

Distância de Gower:

- Para numéricos: Usa a distância de Manhattan (valor absoluto da diferença).
 - Para categóricos: Atribui 0 se forem iguais e 1 se forem diferentes.
-

Resumo Final

PCA e K-Médias: Ferramentas principais para redução de dimensão e agrupamento de dados numéricos.

Consistência: Para dados bem estruturados, a maioria dos métodos produzirá resultados semelhantes.

Importância do Pré-processamento: O sucesso do aprendizado não supervisionado depende quase inteiramente de um escalonamento adequado e da escolha correta da métrica de similaridade.