



Getting Started with pandas

Python for Data Analysis - Cap. 5



Estruturas de Dados

- **Series:** Array unidimensional rotulado;
- **DataFrame:** Tabela bidimensional (linhas + colunas);
- **Index:** Objetos que armazenam os rótulos.

```
In [4]: obj = Series([4, 7, -5, 3])
```

```
In [5]: obj
```

```
Out[5]:
```

```
0    4
1    7
2   -5
3    3
```

Figura 3: declaração básica de uma *Series*

```
data = {'state': ['Ohio', 'Ohio', 'Ohio', 'Nevada', 'Nevada'],
        'year': [2000, 2001, 2002, 2001, 2002],
        'pop': [1.5, 1.7, 3.6, 2.4, 2.9]}
frame = DataFrame(data)
```

```
In [38]: frame
```

```
Out[38]:
```

	pop	state	year
0	1.5	Ohio	2000
1	1.7	Ohio	2001
2	3.6	Ohio	2002
3	2.4	Nevada	2001
4	2.9	Nevada	2002

Figuras 1 e 2: declaração básica de um *DataFrame* e sua saída resultante

Funcionalidades Essenciais

- Reindexação de dados;
- Exclusão de entradas de um eixo;
- Indexação, seleção e filtragem de dados;
- Operações aritméticas e alinhamento automático;
- Aplicação de funções e mapeamento;
- Ordenação e ranking;
- Índices duplicados.

Estatísticas

- Estatísticas descritivas integradas (média, soma, etc.);
- Correlação e covariância;
- Valores únicos e contagem de frequências.

Dados faltantes

- Identificação de valores ausentes;
- Remoção de dados faltantes;
- Preenchimento de valores ausentes (métodos variados).

Indexação Hierárquica

- Indexação em múltiplos níveis (multi-index);
- Reordenação e agregação por níveis;
- Indexação por inteiros;
- Painéis (dados 3D).



Data Loading, Storage, and File Formats

Python for Data Analysis - Cap. 6



Entrada/Saída de Dados

- Importância da leitura/escrita em diferentes formatos;
- Pandas simplifica importação e exportação;
- Integração com várias fontes de dados.

Arquivos de Texto

- **Funções principais:** `read_csv`, `read_table`;
- Customização de delimitadores e cabeçalhos;
- Definição de índices e *parsing* de datas;
- Leitura em pedaços (*chunks*) para grandes volumes;
- Escrita de dados com `to_csv`;
- Trabalhando manualmente com formatos delimitados.

Formatos Estruturados e Binários

- **Formatos Estruturados:**

- **JSON:** leitura e conversão para *DataFrame*;
- **XML e HTML:** suporte básico para *web scraping*.

- **Formatos Binários:**

- **Pickle:** serialização de objetos em *Python*;
- **HDF5:** eficiente para grandes volumes de dados
- **Excel:** leitura de arquivos `.xls` e `.xlsx`.

APIs, Web e Banco de Dados

- Coleta de dados via *APIs (HTTP + JSON)*;
- Conversão direta em *DataFrames*;
- Interação com *HTML*;
- Leitura e escrita em bancos *SQL*;
- Integração com *MongoDB*;
- Facilidade de transformar consultas em *DataFrames*.