




# MANIPULAÇÃO DE DADOS: JUNTAR, COMBINAR E REESTRUTURAR

Ferramentas Essenciais do pandas para  
Combinar e Reestruturar Dados


# INDEXAÇÃO HIERÁRQUICA (MULTIINDEX)

Permite ter múltiplos (dois ou mais) níveis de índice em um eixo (axis). É uma forma de trabalhar com dados de alta dimensão em um formato de baixa dimensão, como uma **Series** ou **DataFrame**.

```
import pandas as pd
import numpy as np
data = pd.Series(np.random.uniform(size=9),
                  index=[["a", "a", "a", "b", "b", "c", "c", "d", "d"],
                        [1, 2, 3, 1, 3, 1, 2, 2, 3]])
print(data)
```

|   |   |          |   |   |          |
|---|---|----------|---|---|----------|
| a | 1 | 0.929616 | c | 1 | 0.595545 |
|   | 2 | 0.316376 |   | 2 | 0.964515 |
|   | 3 | 0.183919 | d | 2 | 0.653177 |
| b | 1 | 0.204560 |   | 3 | 0.748907 |
|   | 3 | 0.567725 |   |   |          |

# INDEXAÇÃO HIERÁRQUICA (MULTIINDEX)



## Indexação Parcial:

Permite selecionar subconjuntos de dados de forma concisa.

```
print(data.loc[:, 2]) # Seleção no nível interno (nível 2)
```

```
a 0.316376  
c 0.964515  
d 0.653177
```

# INDEXAÇÃO HIERÁRQUICA (MULTIINDEX)

## Reestruturação:

Os métodos `unstack()` e `stack()` são inversos e permitem reorganizar os dados entre eixos.

A DataFrame também pode ter índices hierárquicos em ambos os eixos, e os métodos como `swaplevel()` e `sort_index()` permitem reorganizar a ordem dos níveis.

```
data_unstacked = data.unstack()
print(data_unstacked)
```

|   | 1        | 2        | 3        |
|---|----------|----------|----------|
| a | 0.929616 | 0.316376 | 0.183919 |
| b | 0.204560 | NaN      | 0.567725 |
| c | 0.595545 | 0.964515 | NaN      |
| d | NaN      | 0.653177 | 0.748907 |



## Funções Principais:


- `pd.merge`: Conecta linhas em DataFrames com base em uma ou mais chaves (operações de join como em SQL).
- `pd.concat`: Concatena ou "empilha" objetos ao longo de um eixo.
- `combine_first`: Une dados sobrepostos para preencher valores ausentes.



COMBINANDO E  
MESCLANDO  
DATASETS

```
df1 = pd.DataFrame({'key': ["b", "b", "a", "c"], 'data1': range(4)})  
df2 = pd.DataFrame({'key': ["a", "b", "d"], 'data2': range(3)})  
pd.merge(df1, df2, on="key") # Inner Join (Padrão)
```

|   | key | data1 | data2 |
|---|-----|-------|-------|
| 0 | b   | 0     | 1     |
| 1 | b   | 1     | 1     |
| 2 | a   | 2     | 0     |



COMBINANDO E  
MESCLANDO  
DATASETS

## Tipos de Join (how argument):

- 'inner' (Padrão): Interseção das chaves.
- 'left': Inclui todas as chaves da tabela da esquerda.
- 'right': Inclui todas as chaves da tabela da direita.
- 'outer': União de todas as chaves.

```
print(pd.merge(df1, df2, how="outer"))
```

|   | key | data1 | data2 |
|---|-----|-------|-------|
| 0 | b   | 0.0   | 1.0   |
| 1 | b   | 1.0   | 1.0   |
| 2 | a   | 2.0   | 0.0   |
| 3 | c   | 3.0   | NaN   |




COMBINANDO E  
MESCLANDO  
DATASETS

## **pd.concat:**

Une objetos ao longo de um eixo.

```
s1 = pd.Series([0, 1], index=["a", "b"])  
s2 = pd.Series([2, 3], index=["c", "d"])  
print(pd.concat([s1, s2])) # Padrão: axis=0 (linhas)  
print(pd.concat([s1, s2], axis=1)) # axis=1 (colunas)
```

|   |   |
|---|---|
| a | 0 |
| b | 1 |
| c | 2 |
| d | 3 |




COMBINANDO E  
MESCLANDO  
DATASETS

## Mesclagem em Índice:

Use `left_index=True` ou `right_index=True` para usar o índice do DataFrame como a chave de mesclagem.

```
left1 = pd.DataFrame({'key': ["a", "b"]}, index=[0, 1])
right1 = pd.DataFrame({'group_val': [3.5, 7]}, index=["a", "b"])
pd.merge(left1, right1, left_on="key", right_index=True)
```



COMBINANDO E  
MESCLANDO  
DATASETS

|   | key | group_val |
|---|-----|-----------|
| 0 | a   | 3.5       |
| 1 | b   | 7.0       |




## **combine\_first:**

Preenche valores ausentes (NaN) em um objeto com valores de outro objeto com índices sobrepostos.

```
a = pd.Series([np.nan, 2.5, 0.0], index=['f', 'e', 'd'])  
b = pd.Series([0.0, np.nan, 2.0], index=['d', 'e', 'f'])  
print(a.combine_first(b))
```

|   |     |
|---|-----|
| d | 0.0 |
| e | 2.5 |
| f | 5.0 |



COMBINANDO E  
MESCLANDO  
DATASETS



# REESTRUTURAÇÃO E PIVOTAMENTO

stack vs. unstack: A Indexação Hierárquica é a base para as operações de reestruturação:

- stack: Pivota as colunas para as linhas (torna o DataFrame mais longo).
- unstack: Pivota as linhas para as colunas (torna o DataFrame mais largo).





# REESTRUTURAÇÃO E PIVOTAMENTO

## Pivotamento 'Long' para 'Wide' (pivot)

Comum em bases de dados relacionais onde cada observação é uma linha.

```
long_data = pd.DataFrame({  
    'date': ['2023-01-01', '2023-01-01', '2023-01-02', '2023-01-02'],  
    'item': ['gdp', 'infl', 'gdp', 'infl'],  
    'value': [100, 2, 105, 3]  
})  
pivoted = long_data.pivot(index="date", columns="item",  
    values="value")  
print(pivoted)
```

| item       | gdp | infl |
|------------|-----|------|
| date       |     |      |
| 2023-01-01 | 100 | 2    |
| 2023-01-02 | 105 | 3    |



# REESTRUTURAÇÃO E PIVOTAMENTO

## **melt (Derretimento):**

Inverso de pivot. Mescla múltiplas colunas em uma, tornando o DataFrame mais longo e menos largo.

```
df = pd.DataFrame({'key': ["foo", "bar"], 'A': [1, 2], 'B': [4, 5]})  
melted = pd.melt(df, id_vars="key", value_vars=["A", "B"])  
print(melted)
```

|   | key | variable | value |
|---|-----|----------|-------|
| 0 | foo | A        | 1     |
| 1 | bar | A        | 2     |
| 2 | foo | B        | 4     |
| 3 | bar | B        | 5     |




# CONCLUSÃO DO CAPÍTULO 8

## Recursos Chave:

- Indexação Hierárquica: Organiza dados em múltiplos níveis de índice.
- `pd.merge`: Permite joins poderosos (inner, outer, left, right).
- `pd.concat`: Une objetos em linhas ou colunas.
- `pivot` / `melt`: Essenciais para alternar entre formatos longo e largo, fundamentais para a preparação de modelos e relatórios.







Referência: Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter; by Wes McKinney

# MUITO OBRIGADA!

UNIVERSIDADE FEDERAL DO PIAUÍ  
CCN - CIÊNCIA DA COMPUTAÇÃO  
PROF° RICARDO LIRA E PROF° KELLY LIMA  
BIANCA DA SILVA MAGALHÃES PINHEIRO  
TERESINA, 2025